

BM25: Modello Probabilistico per il Ranked Retrieval

1. Motivazione e contesto

Il modello vettoriale con TF-IDF e cosine similarity interpreta il retrieval come un problema geometrico: documenti e query sono vettori, e la rilevanza corrisponde alla loro vicinanza angolare. Sebbene efficace, questo approccio presenta alcune limitazioni fondamentali:

- la term frequency cresce in modo **lineare**: passare da 1 a 2 occorrenze di un termine ha lo stesso effetto di passare da 100 a 101, il che non è realistico;
- la normalizzazione con la norma L2 non tiene conto in modo esplicito della **lunghezza** del documento come fonte di distorsione.

BM25 (*Best Match 25*), derivato dal modello probabilistico nasce per rispondere a queste critiche introducendo una gestione più controllata della frequenza dei termini e della lunghezza dei documenti.

2. Modello matematico

BM25 deriva da un framework probabilistico. Si considera la rilevanza di un documento rispetto una query come una v.a. bernoulliana.

$$R_{d,q} = \begin{cases} 1 & \iff d \text{ is relevant for } q \\ 0 & \text{otherwise} \end{cases}$$

Lo scopo a questo punto è ordinare i documenti per gli odds dell'evento $R = 1|d, q$

$$O(R = 1|d, q) = \frac{P(R = 1|d, q)}{P(\bar{R} = 1|d, q)}$$

Si parte dalla formula di Bayes

$$P(R = 1|d, q) = \frac{P(d|R, q)P(R|q)}{P(d|q)} \propto P(d|R, q)$$

Assumendo che:

- $P(d|q) = P(d)$ ed è uniforme e indipendente per tutti i documenti.
- $P(R|q)$ è costante.

Quindi, la probabilità che un documento d sia rilevante rispetto alla query q la possiamo vedere come la probabilità di osservare un documento d dall'insieme dei documenti rilevanti R per la query q .

Stimando questa probabilità, il primo modello che si ottiene è il *Binary Independent Model BIM*.

$$\text{BIM}_{d,q} = \sum_{t \in q \wedge d} \text{IDF}(t)$$

Modellando i documenti nello stesso modo di VSM, quello che si ottiene è un modello simile al modello VSM con pesatura TF-IDF. Il problema di questo modello è che non tiene conto della lunghezza dei documenti e della term frequency.

Il modello usato nella pratica, che risolve questi problemi è BM25.

Lo score BM25 di un documento d rispetto a una query q è definito come:

$$\text{BM25}(d, q) = \sum_{t \in q^*} \text{IDF}(t) \cdot \frac{(k_1 + 1) \cdot tf_{t,d}}{k_1 \left[(1 - b) + b \cdot \frac{L_d}{\bar{L}} \right] + tf_{t,d}}$$

dove q^* indica l'insieme dei **termini distinti** della query.

2.1 Componente IDF

$$\text{IDF}(t) = \log \left(\frac{N}{df_t} \right)$$

Simbolo	Significato
N	numero totale di documenti nella collezione
df_t	numero di documenti in cui il termine t compare almeno una volta

Assegna peso elevato ai termini rari e peso basso ai termini ubiqui.

2.2 Componente TF saturante

$$\text{TF-saturation}(t, d) = \frac{(k_1 + 1) \cdot tf_{t,d}}{k_1 \cdot B_d + tf_{t,d}}$$

dove il fattore di normalizzazione della lunghezza è:

$$B_d = (1 - b) + b \cdot \frac{L_d}{\bar{L}}$$

Simbolo	Significato
$tf_{t,d}$	frequenza del termine t nel documento d
L_d	lunghezza del documento d (numero di token)
$\bar{L}$	lunghezza media dei documenti nella collezione
k_1	parametro di saturazione della term frequency
b	parametro di normalizzazione per lunghezza

3. Interpretazione degli iperparametri

Parametro k_1 — saturazione della TF

Il parametro $k_1 \geq 0$ controlla **quanto velocemente il contributo di un termine satura** all'aumentare delle sue occorrenze.

Per un documento di lunghezza media ($B_d = 1$), il fattore TF vale:

$$\frac{(k_1 + 1), tf}{k_1 + tf}$$

- quando $tf \rightarrow \infty$, il fattore si avvicina asintoticamente a $(k_1 + 1)$: le occorrenze aggiuntive smettono di contribuire;
- con $k_1 = 0$, il modello conta solo la **presenza** del termine (binario);
- con k_1 grande, le ripetizioni contano di più a lungo (saturazione lenta);
- valori tipici: $k_1 \in [1.2, 2.0]$.

Intuizione: la prima occorrenza di un termine è molto informativa; la centesima aggiunge pochissima evidenza aggiuntiva.

Parametro b — normalizzazione per lunghezza

Il parametro $b \in [0, 1]$ controlla **quanto la lunghezza del documento penalizza i termini frequenti**.

- $b = 0$: nessuna normalizzazione; i documenti lunghi non sono penalizzati;
- $b = 1$: normalizzazione completa; un termine contribuisce in proporzione alla densità con cui appare nel documento, non alla sua frequenza assoluta;
- valore tipico: $b = 0.75$.

Intuizione: un documento di 1000 parole che contiene un termine 10 volte non è necessariamente più rilevante di uno di 100 parole che lo contiene 2 volte. BM25 corregge questa disparità attraverso B_d .

4. Vantaggi di BM25

Saturazione della TF — a differenza del TF-IDF grezzo, BM25 evita che documenti con molte ripetizioni vengano sopravvalutati. Il guadagno marginale di ogni occorrenza aggiuntiva decresce.

Normalizzazione della lunghezza controllata — la lunghezza del documento viene considerata in modo esplicito e modulabile, senza affidarsi alla sola norma L2 della cosine similarity.

Robustezza dei parametri — con i valori standard ($k_1 \approx 1.5$, $b \approx 0.75$) BM25 produce risultati competitivi su molte collezioni senza necessità di tuning; ciò ne ha favorito la diffusione come *strong baseline* per il first-stage retrieval.

Motivazione probabilistica — la formula è derivata dal *Probabilistic Relevance Framework*, il che fornisce una giustificazione teorica coerente al modello di scoring.

Esercizio Numerico

Consideriamo due documenti d_1 e d_2 e la query q

- d_1 = image compression reduces file size
- d_2 = image format and image storage
- q = image file

Calcoliamo $BM25(d_1, q)$ e $BM25(d_2, q)$. Iniziamo con computare le statistiche necessarie.

Statistiche

Frequenze dei termini ($tf_{t,d}$):

Termine	d_1	d_2
image	1	2
file	1	0

Lunghezze: $L_{d_1} = 5, L_{d_2} = 5$, quindi $\bar{L} = 5$.
Document frequency su $N = 2$ documenti:

Termine	df_t
image	2
file	1

Come parametri, $k_1 = 1.5 = \frac{3}{2}$ e $b = 0.75 = \frac{3}{4}$.

IDF**

$$\begin{aligned} \text{IDF}(t) &= \log \frac{N}{df_t} \\ \text{IDF}(\text{image}) &= \log \left(\frac{2}{2} \right) = \log(1) = 0 \\ \text{IDF}(\text{file}) &= \log \left(\frac{2}{1} \right) = \log 2 \end{aligned}$$

Nota importante: `image` compare in entrambi i documenti ($df = N$), quindi il suo IDF è esattamente zero e non contribuisce allo score. Solo `file` è discriminante.

**Calcolo B_{d_1} e B_{d_2}

Poiché $L_{d_1} = L_{d_2} = \bar{L} = 5$, i due documenti hanno la stessa lunghezza media, quindi:

$$B_{d_1} = B_{d_2} = (1 - 0.75) + 0.75 \cdot \frac{5}{5} = \frac{1}{4} + \frac{3}{4} = 1$$

Calcolo degli score BM25

$B_{d_1} = B_{d_2} = 1$ come prima (le lunghezze non cambiano).

Score di d_1

Contributo di `image` ($tf = 1$):

$$0 \cdot \frac{2.5 \cdot 1}{1.5 + 1} = 0$$

Contributo di `file` ($tf = 1$):

$$\log 2 \cdot \frac{2.5 \cdot 1}{1.5 + 1} = \log 2 \cdot \frac{2.5}{2.5} = \log 2 \cdot 1$$

BM25(d_1, q) = $\log 2 \approx 0.693$

Score di d_2

Contributo di `image` ($tf = 2$):

$$0 \cdot \frac{2.5 \cdot 2}{1.5 + 2} = 0$$

Contributo di `file` ($tf = 0$): termine assente, contributo = 0.

BM25(d_2, q) = 0

Ranking finale

Posizione	Documento	Score BM25
1°	d_1	$\log 2 \approx 0.693$
—	d_2	0

Interpretazione: con questa formula IDF, `image` — presente in tutti i documenti — vale zero e sparisce completamente dal calcolo. d_2 riceve score nullo perché l'unico termine discriminante della query, `file`, non vi compare. Il ranking è interamente determinato da `file`, il termine raro.