

1. Motivazione e contesto

Nei modelli visti finora (TF-IDF, BM25) il ranking è costruito assegnando esplicitamente un peso ai termini e sommando i contributi. I **Language Models per IR** adottano un punto di vista radicalmente diverso, di natura **generativa**:

Invece di chiedersi *"quanto è rilevante il documento per la query?"*, ci si chiede *"quanto è probabile che questo documento abbia generato la query?"*

Formalmente, per ogni documento d si stima un modello linguistico M_d e si ordinano i documenti secondo la **query likelihood**:

$$P(q \mid M_d)$$

Il documento che, secondo il proprio modello linguistico, assegna la probabilità più alta alla query viene restituito per primo.

2. Modello matematico

2.1 Modello unigramma

Nella sua forma più semplice si usa un modello **unigramma**: i termini della query sono considerati indipendenti, e la probabilità della query è il prodotto delle probabilità dei singoli termini:

$$P(q \mid M_d) = \prod_{t \in q} P(t \mid M_d)$$

Per evitare underflow numerico si lavora in log-spazio:

$$\log P(q \mid M_d) = \sum_{t \in q} \log P(t \mid M_d)$$

Il documento con log-likelihood più alta vince il ranking.

2.2 Stima di massima verosimiglianza

La stima più naturale di $P(t \mid M_d)$ è la **Maximum Likelihood Estimation (MLE)**:

$$P_{\text{MLE}}(t \mid M_d) = \frac{tf_{t,d}}{L_d}$$

dove $tf_{t,d}$ è la frequenza del termine t nel documento d e L_d è la sua lunghezza. Questa stima è intuitiva ma presenta un problema critico.

2.3 Il problema dello zero

Se un termine della query non compare nel documento, allora:

$$P_{\text{MLE}}(t \mid M_d) = \frac{0}{L_d} = 0$$

e di conseguenza:

$$P(q \mid M_d) = \prod_{t \in q} P(t \mid M_d) = 0$$

Un solo termine assente azzerà l'intero score, anche se il documento contiene tutti gli altri termini della query. Questo rende la MLE inutilizzabile nella pratica: è necessario lo **smoothing**.

3. Vantaggi dei Language Models

Fondamento probabilistico rigoroso — il ranking emerge direttamente da una probabilità ben definita, con una semantica chiara: la verosimiglianza che il documento abbia generato la query.

Gestione naturale della query likelihood — sommare log-probabilità è computazionalmente stabile e interpretabile: ogni termine contribuisce in modo additivo e indipendente.

Effetto IDF implicito — non esiste un termine IDF esplicito come in BM25, ma lo smoothing introduce implicitamente un effetto analogo: i termini rari nella collezione producono un guadagno maggiore quando compaiono nel documento (si veda la sezione 4.3).

Flessibilità — il framework si estende facilmente a modelli di ordine superiore (bigrammi, trigrammi), a query espanse, o a modelli neurali.

4. Smoothing

L'idea comune a tutte le tecniche di smoothing è **interpolare il modello del documento con un modello di background della collezione** $P(t \mid C)$, stimato come:

$$P(t \mid C) = \frac{cf_t}{\sum_{t'} cf_{t'}}$$

dove cf_t è la collection frequency del termine t .

Questo garantisce che nessun termine abbia probabilità zero: anche se t non compare in d , la sua probabilità nel background è positiva.

4.1 Laplace Smoothing (Add-one)

La tecnica più semplice aggiunge 1 a ogni conteggio, distribuendo una piccola massa di probabilità uniformemente su tutto il vocabolario V :

$$P_{\text{Laplace}}(t \mid M_d) = \frac{tf_{t,d} + 1}{L_d + |V|}$$

Vantaggi: semplice, garantisce probabilità positive per ogni termine.

Svantaggi: aggiungere 1 indiscriminatamente è una scelta arbitraria che può distorcere molto le probabilità, specialmente su vocabolari grandi. Non tiene conto della frequenza del termine nella collezione.

4.2 Jelinek-Mercer Smoothing

Interpola linearmente il modello del documento con il modello della collezione tramite un parametro fisso $\lambda \in (0, 1)$:

$$\begin{aligned} P_{\text{JM}}(t \mid M_d) &= (1 - \lambda) \cdot P_{\text{MLE}}(t \mid M_d) + \lambda \cdot P(t \mid C) \\ &= (1 - \lambda) \cdot \frac{tf_{t,d}}{L_d} + \lambda \cdot \frac{cf_t}{\sum_{t'} cf_{t'}} \end{aligned}$$

Vantaggi: intuitivo, facile da implementare. Con λ grande si dà più peso al background (utile per query lunghe); con λ piccolo si privilegia il documento (utile per query corte).

Svantaggi: λ è fisso per tutti i documenti, indipendentemente dalla loro lunghezza. Un documento molto corto e uno molto lungo ricevono lo stesso grado di smoothing, il che non è sempre ottimale.

4.3 Dirichlet Smoothing

Deriva da una prior bayesiana di Dirichlet sul modello del documento. Aggiunge un numero $\mu \cdot P(t \mid C)$ di pseudo-conteggi proporzionale alla frequenza del termine nella collezione:

$$P_{\text{Dir}}(t \mid M_d) = \frac{tf_{t,d} + \mu \cdot P(t \mid C)}{L_d + \mu}$$

Il parametro $\mu > 0$ controlla la forza dello smoothing.

Proprietà chiave — adattività alla lunghezza: per documenti lunghi ($L_d \gg \mu$) il denominatore è dominato da L_d e il modello si fida del documento; per documenti corti ($L_d \ll \mu$) il denominatore è dominato da μ e il modello si fida di più della collezione. Lo smoothing è quindi **automaticamente più forte sui documenti corti**.

Effetto IDF implicito: riscrivendo la formula si può mostrare che un termine raro nella collezione (basso $P(t \mid C)$) produce un guadagno maggiore quando compare nel documento rispetto a un termine comune. Questo riproduce l'intuizione dell'IDF senza introdurlo esplicitamente.

Valori tipici: $\mu \in [500, 2000]$.

4.4 Confronto tra i tre metodi

Laplace	Jelinek-Mercer	Dirichlet	
Parametro	nessuno (add-1)	$\lambda \in (0, 1)$	$\mu > 0$
Background	uniforme	$P(t \mid C)$	$P(t \mid C)$
Adattivo alla lunghezza	No	No	Sì
Effetto IDF implicito	No	Parziale	Sì
Uso pratico	Raro	Query lunghe	Query brevi/web

5. Esercizio numerico

Collezione e query

Siano dati tre documenti (già preprocessati):

d_1 : "cat eat fish" d_2 : "dog eat meat" d_3 : "cat play garden"

Query q : "cat eat"

Token della query: $q = [\text{cat}, \text{eat}]$

Statistiche della collezione ($N = 3$)

Lunghezze dei documenti:

$$L_{d_1} = 3, \quad L_{d_2} = 3, \quad L_{d_3} = 3$$

Collection frequency cf_t (conteggio totale nella collezione):

Termine	d_1	d_2	d_3	cf_t
cat	1	0	1	2
eat	1	1	0	2
fish	1	0	0	1
dog	0	1	0	1
meat	0	1	0	1
play	0	0	1	1
garden	0	0	1	1
Totale				9

Probabilità di background $P(t \mid C) = \frac{cf_t}{9}$:

$$P(\text{cat} \mid C) = \frac{2}{9}, \quad P(\text{eat} \mid C) = \frac{2}{9}$$

Parametro: $\mu = 3$

Calcolo di $P_{\text{Dir}}(t \mid M_d)$

La formula applicata è:

$$P_{\text{Dir}}(t \mid M_d) = \frac{tf_{t,d} + \mu \cdot P(t \mid C)}{L_d + \mu} = \frac{tf_{t,d} + 3 \cdot \frac{cf_t}{9}}{L_d + 3} = \frac{tf_{t,d} + \frac{cf_t}{3}}{L_d + 3}$$

Poiché tutti i documenti hanno $L_d = 3$, il denominatore è sempre $3 + 3 = 6$.

Documento d_1 — "cat eat fish"

$$\begin{aligned} P_{\text{Dir}}(\text{cat} \mid M_{d_1}) &= \frac{1 + \frac{2}{3}}{6} = \frac{\frac{5}{3}}{6} = \frac{5}{18} \\ P_{\text{Dir}}(\text{eat} \mid M_{d_1}) &= \frac{1 + \frac{2}{3}}{6} = \frac{\frac{5}{3}}{6} = \frac{5}{18} \\ \log P(q \mid M_{d_1}) &= \log \frac{5}{18} + \log \frac{5}{18} = 2 \log \frac{5}{18} \end{aligned}$$

Documento d_2 — "dog eat meat"

$$\begin{aligned} P_{\text{Dir}}(\text{cat} \mid M_{d_2}) &= \frac{0 + \frac{2}{3}}{6} = \frac{\frac{2}{3}}{6} = \frac{2}{18} = \frac{1}{9} \\ P_{\text{Dir}}(\text{eat} \mid M_{d_2}) &= \frac{1 + \frac{2}{3}}{6} = \frac{\frac{5}{3}}{6} = \frac{5}{18} \\ \log P(q \mid M_{d_2}) &= \log \frac{1}{9} + \log \frac{5}{18} = \log \frac{5}{162} \end{aligned}$$

Documento d_3 — "cat play garden"

$$\begin{aligned} P_{\text{Dir}}(\text{cat} \mid M_{d_3}) &= \frac{1 + \frac{2}{3}}{6} = \frac{\frac{5}{3}}{6} = \frac{5}{18} \\ P_{\text{Dir}}(\text{eat} \mid M_{d_3}) &= \frac{0 + \frac{2}{3}}{6} = \frac{\frac{2}{3}}{6} = \frac{1}{9} \\ \log P(q \mid M_{d_3}) &= \log \frac{5}{18} + \log \frac{1}{9} = \log \frac{5}{162} \end{aligned}$$

Ranking finale

Posizione	Documento	Score (log-likelihood)
1°	d_1	$2 \log \frac{5}{18}$
2°	d_2	$\log \frac{5}{162}$
2°	d_3	$\log \frac{5}{162}$

Numericamente, usando logaritmo naturale:

$$2 \log \frac{5}{18} = 2 \times (-1.281) \approx -2.563$$

$$\log \frac{5}{162} = \log 5 - \log 162 \approx 1.609 - 5.088 \approx -3.476$$

Poiché $-2.563 > -3.476$, il ranking è:

$$d_1 \succ d_2 = d_3$$

Interpretazione

d_1 è **primo** perché è l'unico documento che contiene **entrambi** i termini della query: `cat` e `eat` compaiono ciascuno con $tf = 1$, il che produce la probabilità smoothed più alta per entrambi i termini.

d_2 e d_3 **sono a pari merito**: ciascuno contiene uno solo dei due termini della query. Lo smoothing di Dirichlet assegna a entrambi una probabilità di background $\frac{1}{9}$ per il termine assente, e una probabilità smoothed $\frac{5}{18}$ per il termine presente. Il prodotto è identico, quindi i due documenti risultano indistinguibili rispetto a questa query.

Ruolo di μ : con $\mu = 3$ lo smoothing è moderato. Aumentando μ le probabilità di tutti i documenti convergerebbero verso il background $P(t \mid C)$, riducendo le differenze tra i documenti e rendendo il ranking meno discriminativo.